



Tema 4. Gestión de datos en un Entorno Grid

Conceptos de la Computación en Grid y Cloud




- Describir la Forma en la que se Manejan los Datos en un Entorno Grid.
- Describir las Formas Más Eficientes de Disponer la Información para su Uso en un Entorno Grid.
- Aplicar los Mecanismos de Globus Toolkit para Acceder y Transmitir Datos.

- Modelos de Acceso a Datos en Grids
 - Necesidades (Proyectos)
 - Conceptos Generales
- Soluciones propuestas por Globus Toolkit
 - Global Access to Secondary Storage (GASS)
 - Integración GASS-GRAM
 - GridFTP

- **Práctica 1:** Lanzamiento de Trabajos Grid RSL (GASS Server – Input/Output).
- **Práctica 2:** Lanzamiento de Trabajos Grid RSL (GASS Server - Staging).
- **Práctica 3:** Lanzamiento de Trabajos Grid (GridFTP).


- **Modelos de Acceso a Datos en Grids**
 - Necesidades (Proyectos)
 - Conceptos Generales
- **Soluciones propuestas por Globus Toolkit**
 - Global Access to Secondary Storage (GASS)
 - Ejemplos
 - Integración GASS-GRAM
 - GridFTP

- Almacenamiento, Preproceso y Análisis de los Datos Obtenidos por el Large Hadron Collider (LHC)
 - El LHC Genera 40 Millones de Colisiones por Segundo.
 - Una Vez Clasificados, Se Analizarán de Forma Intensiva Para Verificar Teorías Correspondientes a la Estructura Básica de la Materia, Como el Boson de Higgs.
 - Tras el Filtrado Quedan 100 Colisiones Interesantes por Segundo.
 - Cada Colisión Genera un Megabyte de Datos, lo que Implica un Ratio de Registro de 0.1 Gigabytes/seg.
 - En Total ~ 10 Petabytes/por Año, lo que Corresponde a 20 millones de CDs por Año!
 - Su Proceso Requeriría $\sim 100,000$ PCs Actuales.



Proyectos - MAGIC (Major Atmospheric Gamma-ray Imaging telesCope)

- Telescopio de 17 metros (Uno de los mas grandes de su Tecnología).
- Ubicado en la Isla de La Palma a 2.200 m. de Altitud.
- El Objetivo es Detectar Fuentes de Rayos Gamma en un Rango Inexplorado.
- Requerimientos
 - Cada Evento Implica ~ 20 kBytes.
 - Se Adquieren 500 Eventos por Seg. ~ 10 MByte/seg.
 - Dado que Hay unas 1.000 h de Observación Anuales, Esto Implica ~ 36 TByte/año.



Modelos de Acceso a Datos en Grids

Conceptos Generales

- Las Aplicaciones Científicas Distribuidas Requieren a Menudo el Acceso a Grandes Cantidades de Datos (Terabytes, Petabytes).
- En estos Casos, el Acceso a Datos Distribuidos es Tan Importante como el Acceso a Recursos de Proceso.
- Por Tanto, Un Objetivo Prioritario es: “Permitir a una Gran Comunidad Geográficamente Distribuida Coordinar sus Recursos para la Realización de Análisis Sofisticados y Computacionalmente Intensivos de Petabytes de Datos”.
- En Cualquier Caso y **de forma General, el Acceso a Datos Implica Simplemente la Transmisión/Acceso de Datos y Resultados De/Desde los Computadores de la Infraestructura Grid Implicados en un Proceso.**

- Generalmente los Grids de Datos Actúan como Grandes Sistemas de **Ficheros Distribuidos y Compartidos**.
 - La Organización de los Datos Es Más Cercana a una Estructura Jerárquica de Directorios que a un Entorno Relacional.
 - No Obstante, Es Posible Definir en Muchos Casos Metadatos que Enriquezcan la Información.
- Los Datos en los Grids Son **Generalmente de Sólo Lectura**.
 - La Modificación Generalmente Implica la Creación de una Nueva Entrada de Datos.

- **La Replicación de Datos es un Factor Importante:**
 - **Fiabilidad y Robustez.** Los Datos Deben Estar Accesibles el Mayor Tiempo Posible.
 - **Eficiencia.** Puede Haber Disponibles Diferentes Copias en Diferentes Ubicaciones Para Repartir Ancho de Banda y Seleccionar los Almacenamientos Más Próximos.
 - **Integridad.** La Condición de Sólo Lectura Simplifica la Coherencia de Diferentes Réplicas.

- Modelos de Acceso a Datos en Grids
 - Necesidades (Proyectos)
 - Conceptos Generales
- **Soluciones propuestas por Globus Toolkit**
 - Introducción
 - Global Access to Secondary Storage (GASS)
 - Integración GASS-GRAM
 - GridFTP

- Acceso a Datos y Transferencia
 - **GASS:** Proporciona Servicios Principalmente Orientados para el GRAM (Redirección de la E/S, Stage de Ficheros).
 - **GridFTP:** Proporciona Altas Prestaciones, Transferencia Fiable sobre Redes WAN.

- Global Access to Secondary Storage (GASS)
Es un Servicio que Permite Manejar Datos Almacenados de Forma Remota.
- GASS Permite Definir Identificadores que Identifican el Recurso, la Ubicación y el Nombre de los Archivos Accesibles por el Sistema.
- GASS Se Integra con los Sistemas de Seguridad, Lanzamiento de Tareas y Comunicaciones de globus.

- **Los Servicios del GASS Permiten:**

- Indicar al Servicio GRAM la Ubicación de los Ejecutables, Entradas o Salidas Cuando Éstos no se Encuentran en la Máquina Destino.
- Acceder a Ficheros de Datos que se Encuentran en un Recurso Diferente del Elegido para la Ejecución.
- Gestionar la Entrada (stdin), Salida (stdout) y Error (stderr) Estándar Desde una Ubicación Remota.

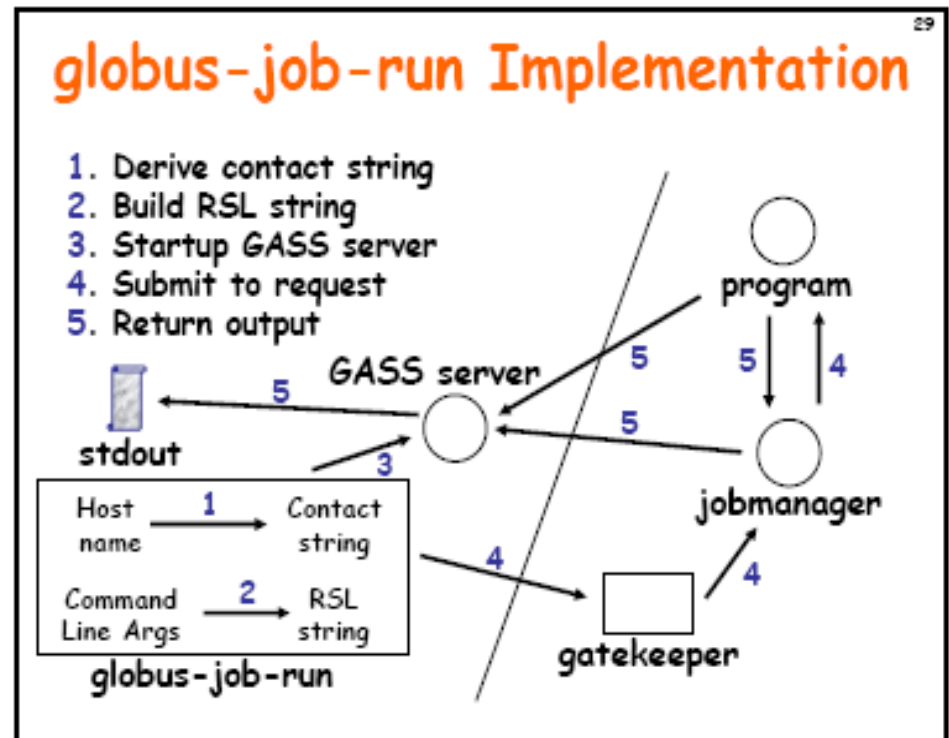
- **GASS**

- Utiliza URLs para Identificar Ejecutables, Ficheros de Datos Entrada, Salida y Error Estándar, en una Sintaxis Integrada en el Resource Specification Language (RSL).
- Permite Sustituir las Llamadas a Funciones de E/S (open/close) por Funciones Equivalentes (globus_gass_open/close, globus_gass_fopen/fclose).

Soluciones Propuestas por Globus Toolkit

GASS – Integración con GRAM

- En la Implementación del Comando globus-job-run se Incluye Directamente el Uso del GASS.
 - A Partir del Nombre de la Máquina y de la Línea de Argumentos se Construyen las Direcciones Remotas para los Datos y Ejecutables (1, 2).
 - Se Activa un Servidor GASS (3).
 - Se Ejecutan Los Trabajos a Partir de globusrun (4).
 - La Salida se Recupera a Través del GASS en el Computador Local (5).



- **Ventajas**

- Carga Transparente y Bajo Demanda de Ficheros de Datos.
- Volcado Automático de Código y Datos en Recursos Remotos.
- Volcado Automático y en Tiempo Real de la Salida Por Pantalla.


- **Limitaciones**

- No es Adecuado para la Transferencia de Grandes Volúmenes de Datos en Entornos de Altas Prestaciones.


- GridFTP Esconde las Particularidades de los Sistemas Proporcionando un Interfaz Único
 - Similar al Papel que Juega GRAM en el Lanzamiento de Trabajos.
- GridFTP está Basado en FTP, Incorporando una Serie de Características Adecuadas para el Grid
 - GridFTP > FTP
 - FTP es el Estándar “De-facto” para la Transferencia de Ficheros.
 - FTP es Interoperable con Muchas Herramientas Propietarias.
- GridFTP Proporciona un Interfaz a Muchos Sistemas de Almacenamiento
 - HPSS, DPSS, Sistemas de Fichero.

GridFTP: Extensiones al FTP

- Integración con GSI
 - Directamente Utiliza las Credenciales del Usuario para la Autenticación.
- Restart Extendido
 - Permite una Recuperación Automática Tras Fallos en las Conexiones.
- Canales de Datos Paralelos
 - Mejora el Ancho de Banda Total Efectivo Mediante la Creación de Múltiples Streams de TCP en Paralelo, Incluso sobre el Mismo Recurso.



- **Transferencia Parcial de Datos**
 - Extensión de los Comandos de FTP para la Transferencia de Partes de un Fichero.
 - No Sólo Implica una Mejora en la Fiabilidad, Sino que Además es Posible Recuperar una Parte Concreta de un Fichero Únicamente.
- **Transferencia de Datos "Stripped"**
 - Múltiples Conexiones desde Servidores Distribuidos Para un Único Fichero.



- **globus-url-copy**
 - Permite la Copia de Ficheros Remotos y Soporta Diversos Protocolos (file://, http://, https://, ftp://, gsiftp://).
 - Necesita Disponer de un Proxy Válido.
- **Sintaxis**
 - globus-url-copy [opciones] URL_Fuente URL_Destino
 - Donde la URL es Cualquier URL Válida Definida en RFC 1738 que Contenga un Protocolo Soportado.
 - Formato URL: **protocol://[host]:[port]/path.**

GridFTP: Ejemplos de URLs

- Especificando Todos los Parámetros
 - `gsiftp://myhost.mydomain.com:2812/data/foo.dat`
- Sin Indicar el Puerto (Por Defecto, 80 en Este Caso)
- Fichero Local (Protocolo File, No Se Especifica Puerto ni Host).
 - `file:///foo.dat`

● Opciones

- -vb | -verbose Mostrar Información Adicional Durante la Transferencia:
 - Número de Bytes Transferidos, Tasa de Envío Actual y Media, etc.
- -dbg | -debug, Muestra Información de Depuración, Muy Adecuado Cuando Hay Problemas.
- -f <filename> Toma de un Fichero la Lista Pares de URLs Para cada Transferencia. Cada Línea del Fichero Debe Tener el Formato: <sourceURL> <destURL> Indicadas entre Comillas. Comentarios Empezados con "#".
- -r | -recurse, Copia Ficheros en los Directorios.

- **Correcto Uso de los Protocolos**
 - file://
 - Permite Especificar Ficheros en la Máquina Local.
 - http://, https://
 - Permite Definir como Fuente un Fichero Accesible por Web.
 - ftp://
 - Permite Acceder a Un Servidor FTP.
 - Admite Lectura y Escritura, Permitiendo Especificar Usuario y Contraseña (Altamente Inseguro).
 - gsiftp://
 - Protocolo Básico del GridFTP.
 - Admite Lectura y Escritura, Requiere que el Demonio de GridFTP esté en Marcha en la Máquina Destino y que el Directorio Especificado Tenga para el Usuario Local los Permisos Correspondientes.
 - Incorpora la Autenticación por GSI.

GridFTP: Ejemplo 3

• Origen

- Host: Local
- Protocolo: file
- Puerto: Por Defecto
- Directorio: /home/profesor
- Fichero: datos.txt

• Destino

- Host: idunv08.i3m.upv.es (Remoto)
- Protocolo: gsiftp
- Puerto: Por Defecto
- Directorio: /home/globus
- Fichero: inp1.txt

```
globus-url-copy file:///home/profesor/datos.txt  
gsiftp://idunv08.i3m.upv.es/home/profesor/datos.txt
```


GridFTP: Ejemplo 4

• Origen

- Host: idunv08.i3m.upv.es (remoto)
- Protocolo: GridFTP
- Puerto: Por Defecto
- Directorio: /proc
- Fichero: cpuinfo

• Destino

- Host: local
- Protocolo: file
- Puerto: Por Defecto
- Directorio: /home/iblanque
- Fichero: cpu_geb.txt

globus-url-copy

<gsiftp://idunv08.i3m.upv.es/home/profesor/datos.txt> <file:///home/profesor/datos2.txt>